

Proyecto final

Calidad y Preprocesamiento de Datos

Licenciatura en Ciencia de Datos

Profesores:

MCIC Víctor Manuel Corza Vargas

MCIC Fernando Avitúa Varela

Lineamientos del proyecto final

Se realizará en equipos de 4 o 5 personas.

Fecha de entrega: miércoles 27 de mayo (No habrá prórroga)

Modalidad de entrega: A través de la plataforma Classroom en la Tarea 'Proyecto Final'

Presentación oral en clase: miércoles 27 de mayo. Contarán con **15 minutos** para su presentación.

Todos los integrantes del equipo deberán contribuir de manera equitativa en la realización de cada etapa del proyecto. La calificación del proyecto se asignará de manera individual.

Objetivos

- Identificar una problemática del mundo real dentro del sector Salud, Finanzas, Educación, etc., ya sea a nivel global o nacional en la que la solución requiera limpieza, preprocesamiento y fusión de datos.
- Establecer necesidades de negocio derivadas del análisis de información.
- Realizar extracción, perfilado y limpieza de la información colectada proveniente de diversas fuentes.
- El equipo deberá seguir los lineamientos establecidos en las áreas de conocimiento relacionadas con la Calidad de Datos del framework de su elección.
- Podrán utilizar las herramientas Data Quality de INFORMATICA, Python o algún otro proveedor que consideren pertinente siempre y cuando sea una herramienta específica de calidad y/o análisis de datos.

Actividades a realizar

I. Elegir fuentes de datos de un área de negocio dentro del sector Salud, Finanzas, Educación, etc., ya sea a nivel global o nacional.

Considerar al menos 2 fuentes de datos y asegurarse de que existan las mismas entidades nombradas de diferente manera y con diferentes datos en las 2 fuentes elegidas. Si no es posible encontrar fuentes con estas características, considerar datos sintéticos.

II. Problemática y entendimiento del negocio

a) Con respecto a las fuentes de datos elegidas, identificar 5 problemáticas de negocio que impliquen mala toma de decisiones derivada de datos de baja calidad en términos de las dimensiones de calidad vistas en clase.

III. Elaborar una propuesta de solución para cada problemática de negocio utilizando análisis predictivo, prescriptivo o descriptivo con las fuentes elegidas.

A partir de esta sección, enmarcar cada fase dentro de algún framework de calidad de datos.

IV. Perfilado de datos

- a. Realizar el perfilado de las fuentes de datos elegidas

VI. Limpieza de datos relevantes

- a. Completar datos
- b. Detectar y eliminar outliers
- c. Forzar patrones de correo, nombres, direcciones, unidades, tipos, etc.

VII. Obtención de datos maestros

- a. Definir un modelo canónico
- b. De-duplicar datos (utilizando record-linkage o una herramienta parecida)
- c. Realizar fusión de datos

VIII. Preprocesamiento de datos, según sea el caso (por ejemplo)

- a. Discretización
- b. Normalización
- c. Reducción de dimensiones
- d. Estandarización
- e. Transformación, etc.

VIII. Análisis de datos a través de minería de datos descriptiva, prescriptiva o predictiva

- a. Resolución de las 5 problemáticas de negocio a partir del análisis de datos
- b. Generar graficas que reflejen claramente los análisis realizados.

Formato de entrega:

I Reporte que contemplen los siguientes aspectos:

1. Marco teórico de Calidad de datos
2. Descripción del área de negocio elegida
3. Descripción de las fuentes de datos elegidas.
4. Problemática y entendimiento del negocio
5. Propuesta de solución para cada problemática de negocio utilizando análisis predictivo, prescriptivo o descriptivo con las fuentes elegidas
6. Reporte del perfilado de datos
7. Reporte del proceso de limpieza de datos.
8. Reporte sobre la obtención de datos maestros
9. Reporte sobre el preprocesamiento de datos realizado.

II Código

1. Código con el procedimiento realizado para el perfilado de datos (Incluir código fuente en un archivo llamado 'perfilado.py' o 'perfilado.ipynb')
2. Código con el procedimiento realizado para la generación de datos maestros (Incluir código fuente en un archivo llamado 'fusion.py' o 'fusion.ipynb')
9. Procedimiento realizado para la limpieza de datos (Incluir código fuente en un archivo aparte llamado 'limpieza.py')
10. Procedimiento realizado para el análisis de los datos (Incluir código fuente en un archivo aparte llamado 'análisis.py')
- a. Código y ejecución de 10 consultas que contengan más de una fuente de datos a la vez. (Con una integración virtualizada o consolidada)

b. Código y ejecución de 5 consultas por cada fuente de datos

11. Los resultados de las consultas se deberán visualizar con diferentes tipos de gráficas.

12. Conclusiones

a) En términos de la realización del proyecto de calidad de datos

b) En términos de dominio de negocio, resultado del análisis.